ESCUELA POLITÉCNICA NACIONAL

Facultad de Ingeniería de Sistemas

Carrera de Ciencia de Datos e Inteligencia Artificial

INFORME DE PRÁCTICA N.º 1

LECTURA DE DATOS

Estadística y Programación para Ciencia de Datos I · IDSD422

Campo	Información
Estudiante	Paula Camila Granda Betancourt
Usuario de GitHub	pgranda71
Docente	Christian Suárez
Período académico	2026-B
Fecha	16/10/2026
Repositorio (fork)	https://github.com/pgranda71/IDSD422-lab1-lectura-datos.git

Informe elaborado a partir de la ejecución de los scripts en Python y R y de los resultados registrados para los archivos ventas.csv, ventas.json y ventas.xlsx.

1. Introducción

RetailAndina S.A. recibe reportes de ventas desde tres sistemas distintos: el ERP de sucursales, una API de fidelización y el consolidado de finanzas. Aunque los reportes están guardados como CSV, JSON y Excel, la gerencia necesita conocer si contienen información comparable y si pueden utilizarse para obtener indicadores comerciales.

En esta práctica leí los tres formatos en Python y R, revisé sus dimensiones y tipos de datos, y calculé indicadores a partir de los registros disponibles. El ejercicio me permitió distinguir entre el formato físico de un archivo y la estructura tabular que se obtiene al procesarlo.

2. Objetivos

Objetivo general. Analizar los reportes de ventas de RetailAndina S.A. almacenados en CSV, JSON y Excel mediante Python y R, para comprobar su estructura y obtener indicadores descriptivos.

Objetivos específicos:

- Leer cada formato utilizando funciones y librerías adecuadas en Python y R.
- Comprobar dimensiones, nombres y tipos de las variables obtenidas en ambas herramientas.
- Calcular ticket promedio y comparar ventas por sucursal y región.
- Documentar dificultades técnicas, resultados y recomendaciones sustentadas en la práctica.

3. Desarrollo de la práctica

3.1. Carga y comparación de formatos

Cargué los archivos desde la carpeta data/ del repositorio y revisé las primeras filas y la cantidad de columnas. Al importar los datos, observé cinco filas y cuatro variables en los tres formatos.

Formato	Python	R	Dimensiones
CSV	pd.read_csv()	read.csv()	5 × 4
JSON	json.load() + pd.json_normalize()	jsonlite::fromJSON()	5 × 4
Excel	pd.read_excel(sheet_name="ventas")	readxl::read_excel(sheet="ventas")	5 × 4

En CSV la información estaba separada por delimitadores; para JSON utilicé una función que convirtió los registros a tabla; y en Excel indiqué expresamente la hoja “ventas”. El formato cambia el método de lectura, pero los registros observados coincidieron entre las fuentes.

3.2. Inspección de tipos y calidad

Revisé las variables sucursal, region, ventas y clientes. Las dos primeras son categóricas; las restantes son numéricas y permiten realizar sumas, promedios y agrupaciones.

Variable	Python	R (CSV/JSON)	R (Excel)
sucursal	str / object	character	character
region	str / object	character	character
ventas	int64	integer	numeric (double)
clientes	int64	integer	numeric (double)

Una columna de ventas importada como texto podría indicar valores con símbolos, espacios o caracteres inesperados. Antes del análisis sería necesario revisar los registros y convertirlos a un tipo numérico válido. En la ejecución observada no apareció este problema.

3.3. Procedimiento e incidencias

Utilicé Google Colab y VS Code para Python, y Posit Cloud para R. Durante la ejecución local de un script en Python apareció un error de archivo no encontrado porque la ruta "/content/data/ventas.csv" pertenecía al entorno de Colab. Lo corregí por "data/ventas.csv" al ejecutar desde la raíz del repositorio.

En R utilicé jsonlite para leer JSON y readxl para Excel. También corregí una primera referencia errónea al nombre de un archivo JSON. Tras estas correcciones, las lecturas mostraron cinco registros y cuatro variables.

Fragmentos representativos del código utilizado:

```
# Python: carga y verificación de dimensiones
ventas = pd.read_csv("data/ventas.csv")
print(ventas.shape)
print(ventas.dtypes)
# R: inspección y cálculo del ticket
ventas <- read.csv("data/ventas.csv")
str(ventas)
ventas$ticket <- ventas$ventas / ventas$clientes
```

3.4. Indicadores comerciales

Calculé los indicadores descriptivos a partir de los cinco registros, usando agrupaciones por sucursal y región. Para el ticket general dividí la suma de ventas entre la suma de clientes, sin utilizar el promedio simple de los tickets individuales.

Indicador	Resultado
Venta promedio entre las cinco sucursales	12.008
Ticket promedio general	38,07
Sucursal de mayor venta	Guayaquil Centro: 15.200
Sucursal de menor venta	Cuenca: 8.540
Región con mayor venta total	Sierra: 30.860

3.5. Interpretación de resultados

Guayaquil Centro registró el mayor valor de ventas entre las sucursales analizadas, mientras que Cuenca presentó el menor. Sierra acumuló 30.860, superando a Costa, que alcanzó 29.180. En el archivo, cada sucursal tiene un solo registro, por lo que su venta individual y el promedio por esa sucursal coinciden.

El ticket promedio general fue 38,07. Lo interpreté como el valor promedio de ventas por cliente para el conjunto de registros del ejercicio. Este resultado describe únicamente la información disponible; no constituye una proyección de ventas futuras.

4. ¿Qué aprendí con esta práctica?

Aprendí a cargar la misma información desde distintos formatos y a comprobar que sus resultados sean comparables en dos lenguajes. Antes de esta práctica, no distinguía con tanta claridad entre la estructura de JSON y su representación como tabla; al utilizar json_normalize() y fromJSON() comprendí mejor esa conversión.

También reforcé la revisión de los tipos de datos. Observé que R puede importar una variable de Excel como double y la misma variable de CSV como integer, sin que ello signifique que hayan cambiado las ventas. En Python confirmé la utilidad de dtypes y en R la de str() para anticipar problemas de cálculo.

Una dificultad concreta fue el manejo de rutas. El código que funcionaba en Colab no encontraba el CSV cuando lo ejecutaba en VS Code. Revisé la ubicación del archivo y adapté la ruta al repositorio local. Para futuras prácticas comprobaría primero el directorio de trabajo, registraría los resultados de cada ejecución y prepararía las evidencias conforme avance.

5. Conclusiones

1. Los tres reportes se leyeron como tablas de cinco filas y cuatro columnas en Python y R. Los resultados observados respaldan que las fuentes contienen registros comparables, aunque es aconsejable validar automáticamente todos los valores antes de integrar reportes mayores.

2. Los tipos inferidos fueron adecuados: ventas y clientes se representaron numéricamente, y sucursal y region como texto. Las diferencias entre integer y double al importar Excel en R no impidieron calcular indicadores.

3. Los resultados permitieron identificar a Guayaquil Centro como la sucursal de mayor venta (15.200), a Cuenca como la de menor (8.540) y a Sierra como la región de mayor venta (30.860). Recomendaría a la gerencia establecer verificaciones de tipos, duplicados y consistencia antes de automatizar el consolidado. Estos hallazgos describen cinco sucursales del período trabajado y no permiten proyectar tendencias por sí solos.

6. Bibliografía

pandas development team. (s. f.). pandas.read_csv. Documentación de pandas. https://pandas.pydata.org/docs/reference/api/pandas.read_csv.html

Wickham, H., y Bryan, J. (s. f.). readxl: Read Excel Files. Documentación de readxl. https://readxl.tidyverse.org/

Ooms, J. (s. f.). jsonlite: A Simple and Robust JSON Parser and Generator for R. https://cran.r-project.org/package=jsonlite

RetailAndina S.A. (2026). Reportes de ventas de la semana 39: ventas.csv, ventas.json y ventas.xlsx [Archivos de práctica suministrados en el repositorio].

Declaración de uso de inteligencia artificial

Utilicé ChatGPT como apoyo para organizar el informe, revisar la redacción y explicar funciones de Python y R. Los cálculos y las capturas corresponden a los resultados de las ejecuciones compartidas durante la práctica; revisé el contenido antes de preparar la entrega.

Repositorio del trabajo

https://github.com/pgranda71/IDSD422-lab1-lectura-datos.git

Evidencias y anexos

En las páginas siguientes incluyo capturas de ejecuciones propias compartidas durante el desarrollo. Mantengo cada captura completa para mostrar el entorno y la salida sin ocultar su contexto.

Anexo A. Evidencia en Python

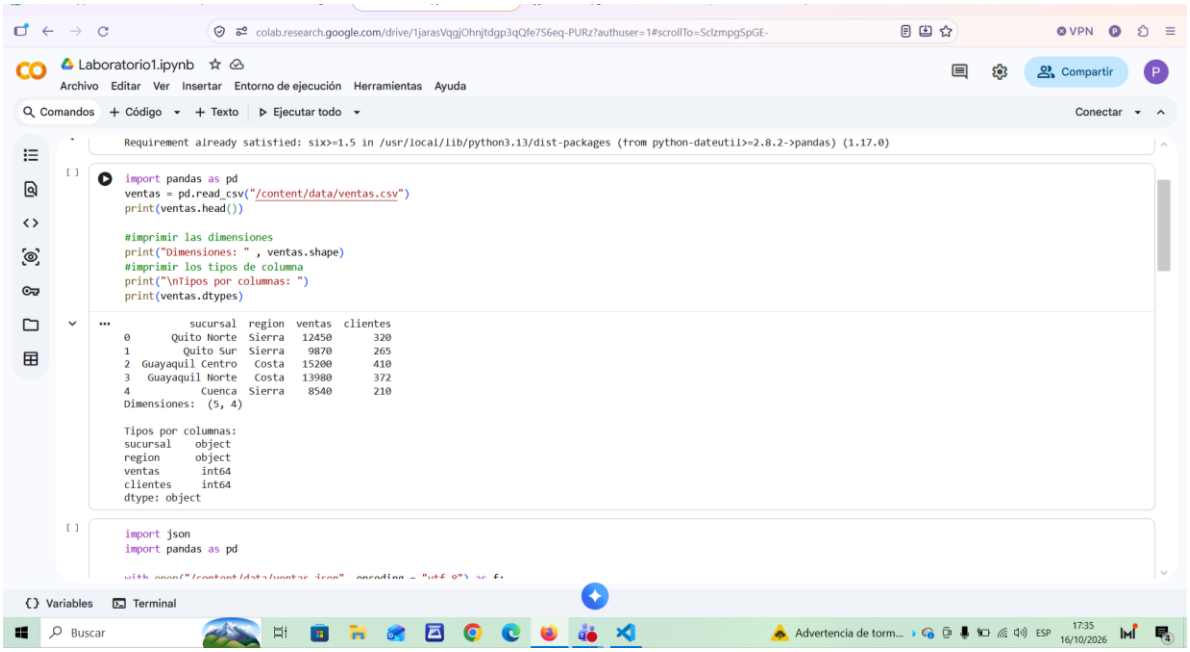


Figura 1. Lectura del CSV en Google Colab: primeras filas, dimensiones (5, 4) y tipos de las columnas.

Anexo B. Evidencia en R

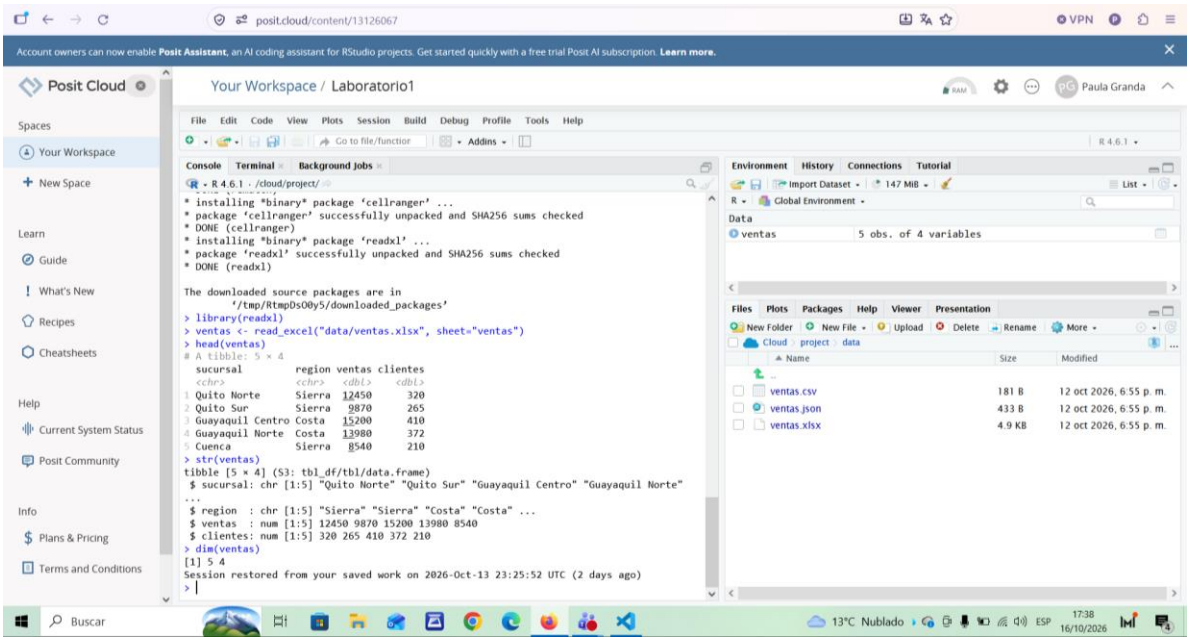


Figura 2. Lectura del Excel en Posit Cloud con readxl: estructura de 5 filas y 4 variables.

Anexo C. Código de inspección en Python

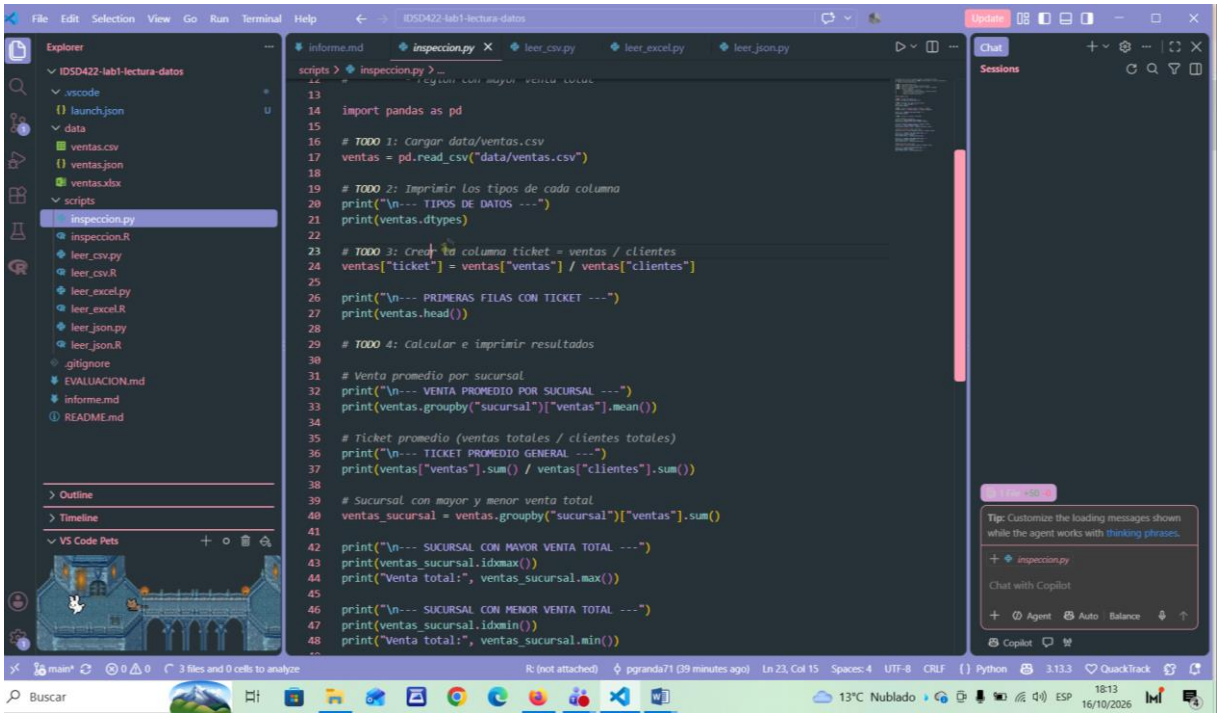


Figura 3. Código de inspección en Python: lectura del CSV, tipos de datos, cálculo del ticket e indicadores por sucursal.

Anexo D. Resultados de inspección en Python

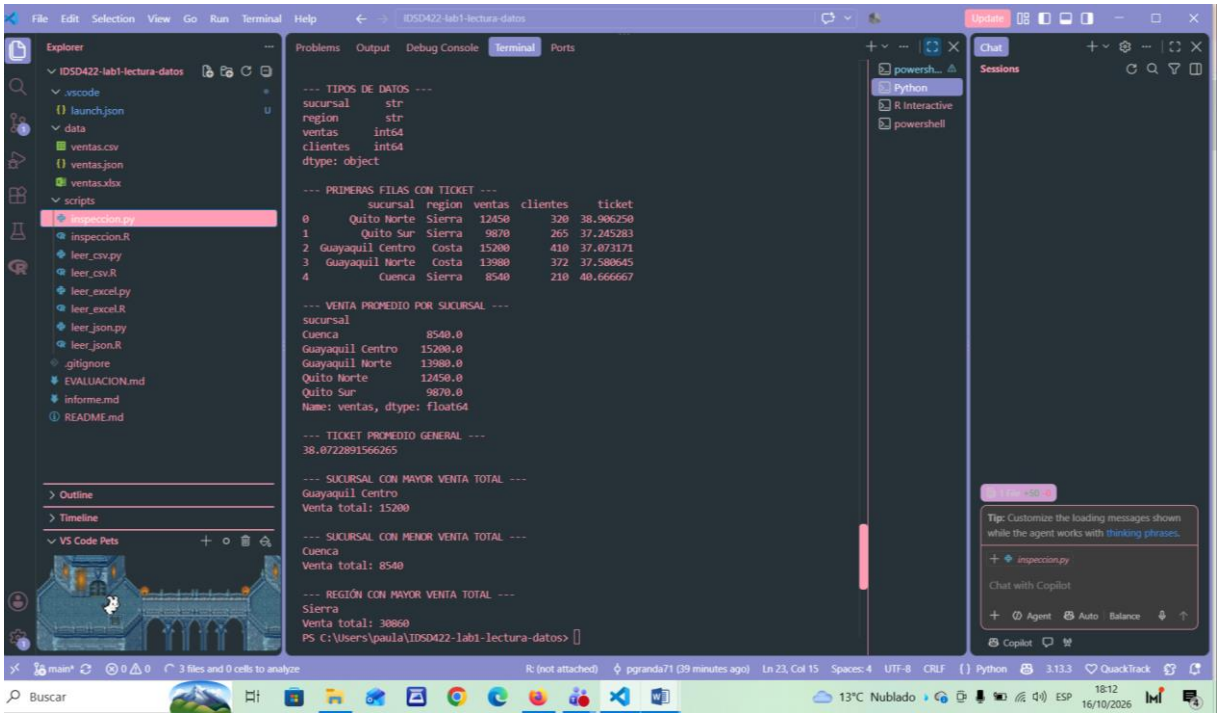


Figura 4. Resultados de inspección en Python: ticket promedio, ventas por sucursal y región con mayor venta total.

Anexo E. Evidencias adicionales de la práctica

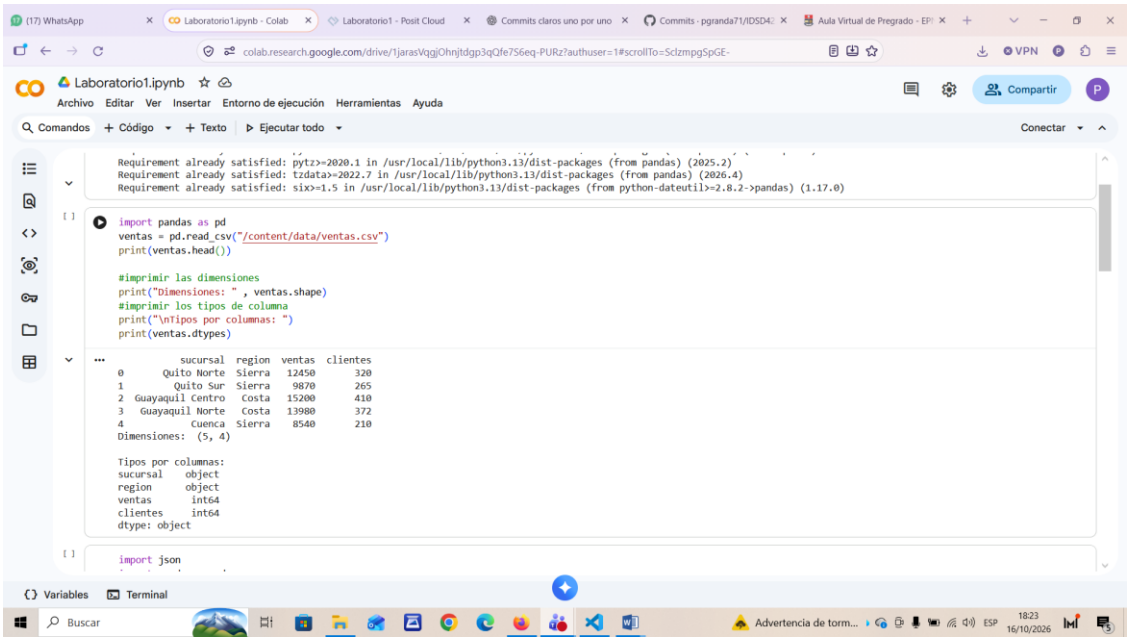


Figura 5. Lectura de CSV en Google Colab: registros, dimensiones y tipos de datos.

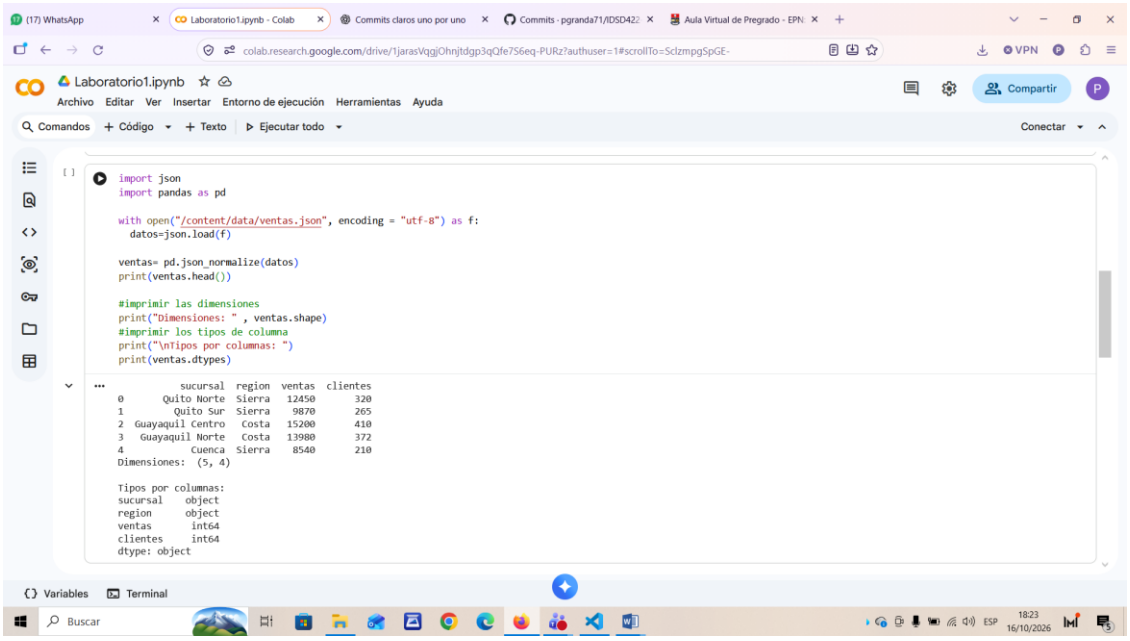


Figura 6. Lectura de JSON en Google Colab: normalización de registros y verificación de su estructura.

Anexo F. Evidencias adicionales de la práctica

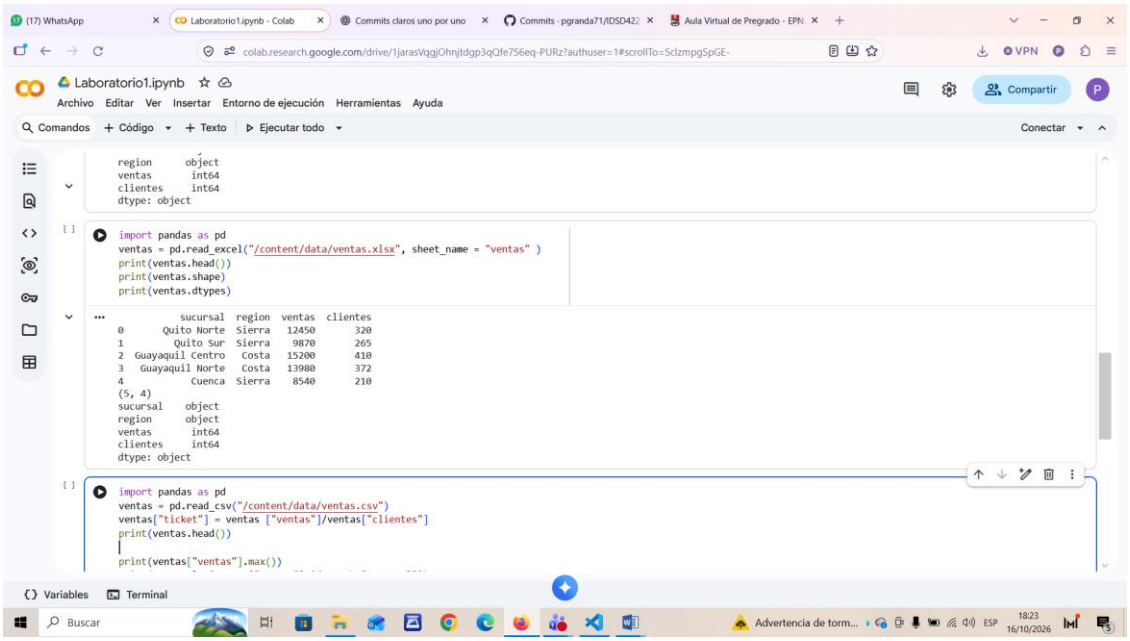


Figura 7. Lectura de Excel en Google Colab: hoja ventas, dimensiones y tipos de columnas.

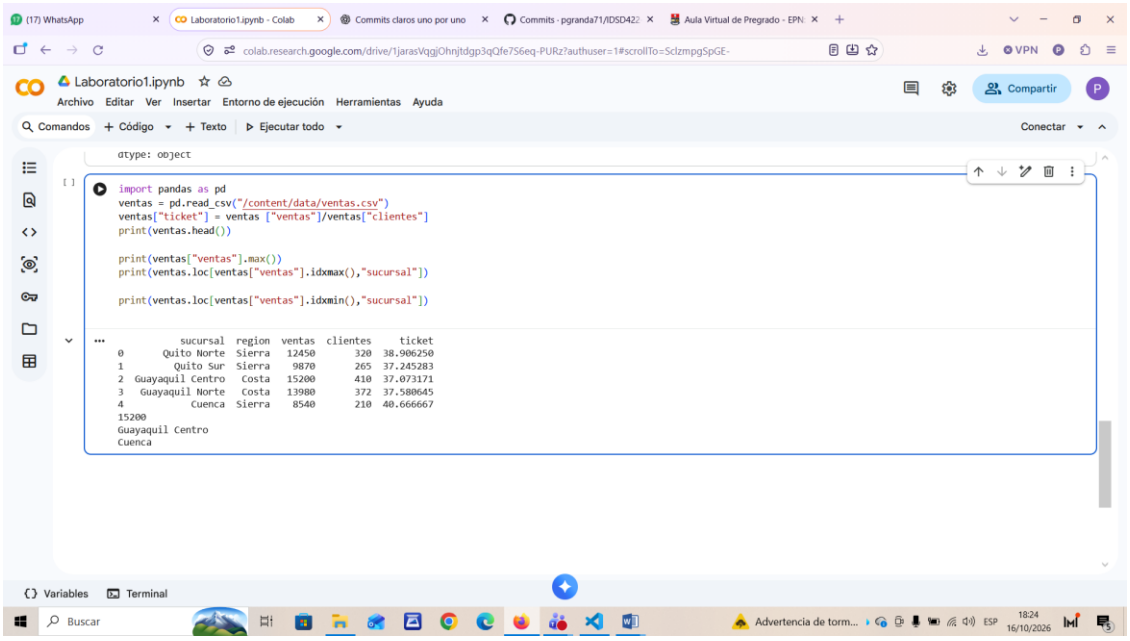


Figura 8. Cálculo inicial del ticket y consulta de sucursales en Google Colab.

Anexo G. Evidencias adicionales de la práctica

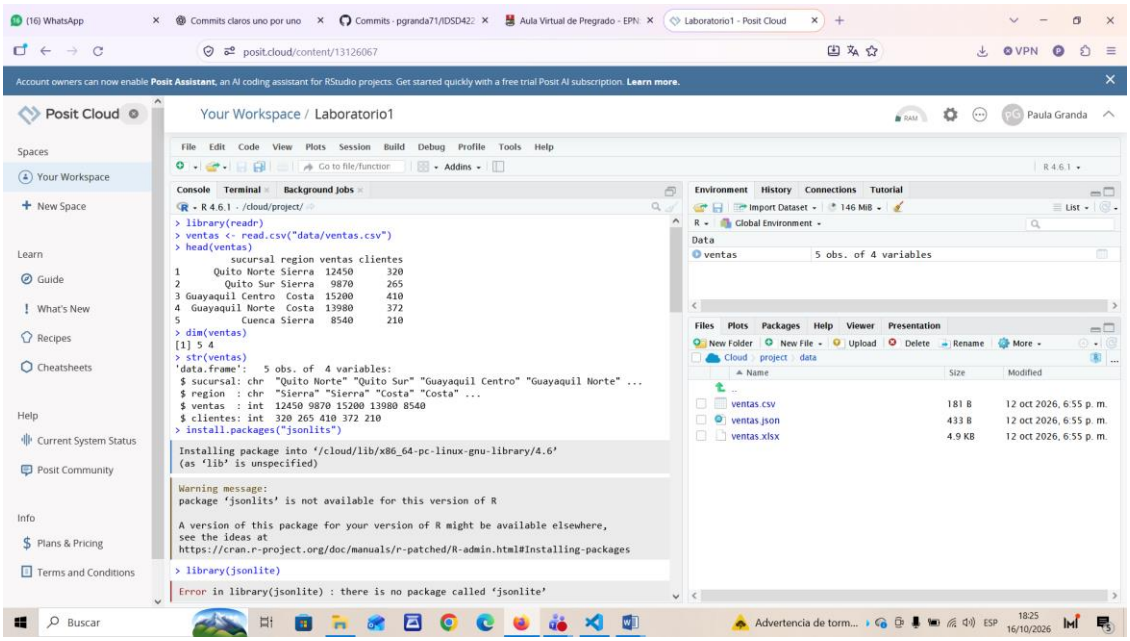


Figura 9. Lectura de CSV en Posit Cloud: verificación de estructura e incidencia con paquete JSON.

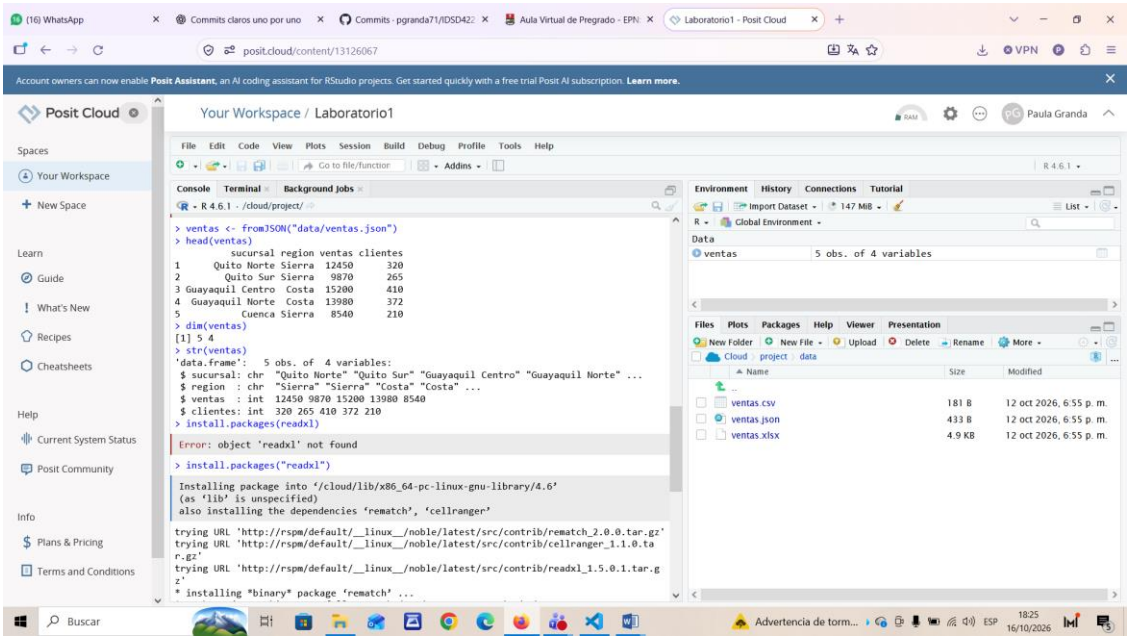


Figura 10. Lectura de JSON en Posit Cloud y preparación de la librería para Excel.

Anexo H. Evidencias adicionales de la práctica

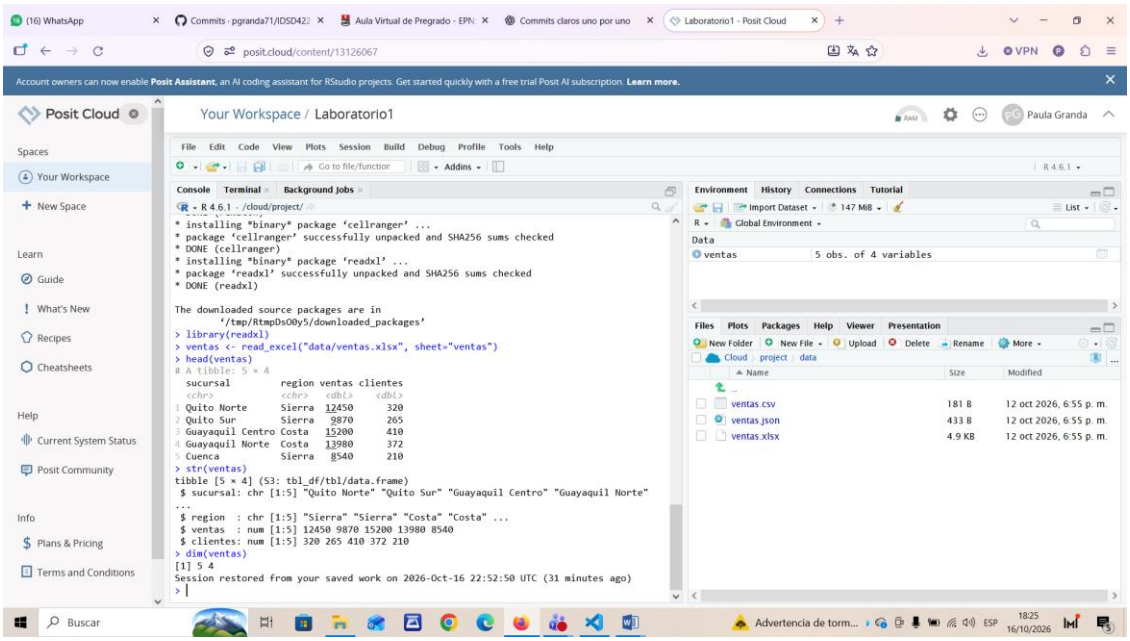


Figura 11. Lectura de Excel en Posit Cloud: cinco registros y cuatro variables.

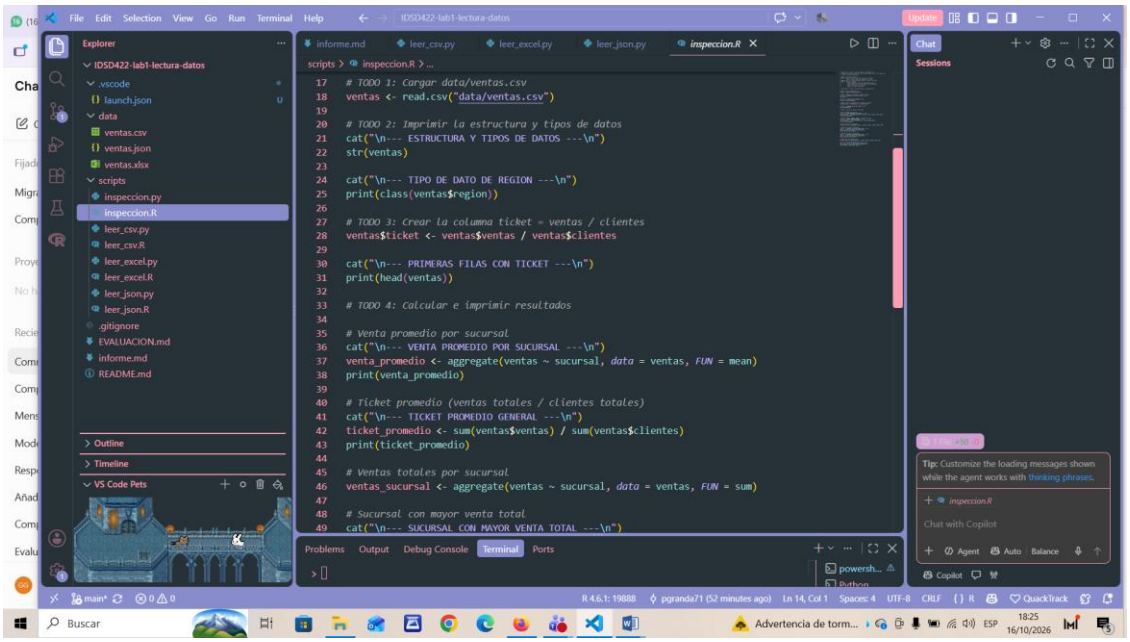


Figura 12. Código de inspección en R: lectura, tipos y cálculo del ticket promedio.

Anexo I. Evidencias adicionales de la práctica

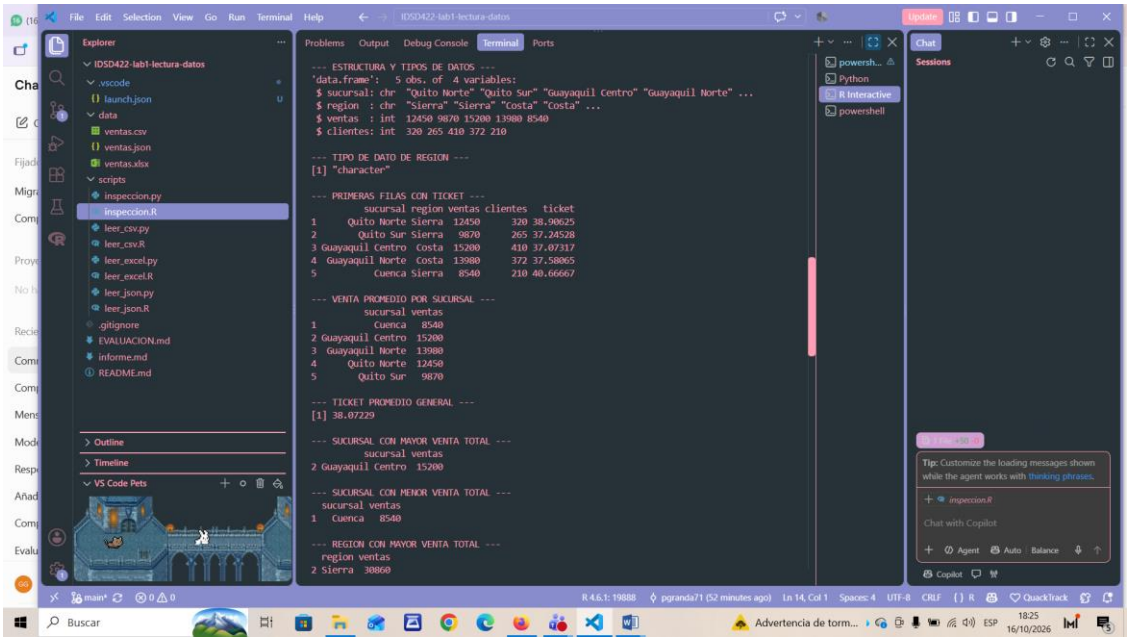


Figura 13. Resultados de inspección en R: indicadores por sucursal y región.